

Київський національний університет імені Тараса Шевченка  
Факультет комп'ютерних наук та кібернетики

Рандомізована паралельна декомпозиція для  
розв'язання операторних включень

Виконав:

Білінський Павло

3 курс

Кафедра Обчислювальної математики

Науковий керівник:

Семенов Володимир Вікторович

13 травня 2021 р.

# Зміст

|          |   |          |
|----------|---|----------|
| <b>1</b> | <b>Постановка задачі</b>                                      | <b>1</b> |
| <b>2</b> | <b>Актуальність проблеми</b>                                  | <b>2</b> |
| <b>3</b> | <b>Стаття Bianchi: ергодична збіжність</b>                    | <b>3</b> |
| 3.1      | Постановка задачі . . . . .                                   | 3        |
| 3.2      | Основні поняття . . . . .                                     | 3        |
| 3.3      | Основні результати . . . . .                                  | 3        |
| 3.4      | Висновок . . . . .  | 4        |
| <b>4</b> | <b>Випадок <math>A = \partial f</math></b>                    | <b>4</b> |
| 4.1      | Градiєнтний спуск . . . . .                                   | 4        |
| 4.2      | Проксимальний алгоритм . . . . .                              | 5        |
| 4.3      | Проекційний алгоритм для пошуку умовного екстремуму . . . . . | 5        |
| <b>A</b> | <b>Основні визначення та позначення</b>                       | <b>6</b> |

## 1 Постановка задачі

Нехай в гільбертовому просторі  $\mathcal{H}$  задані багатозначні оператори  $A_1, A_2, \dots, A_m$ . Потрібно знайти такі  $x \in \mathcal{H}$ , що

$$0 \in A_1(x) + A_2(x) + \dots + A_m(x) \quad (1)$$

Зазвичай ми припускаємо, що оператори  $A_i$  - монотонні, більше того, максимально монотонні. В роботі [?] був запропонований алгоритм:

### *Алгоритм*

1) *Задаємо  $\{\lambda_n\} \subseteq (0, +\infty)$ ,  $x_1 \in \mathcal{H}$ ;  $n := 1$ .*

2) *Знаходимо елементи*

$$x_{i,n} = J_{\lambda_n A_i} x_n, \quad i = \overline{1, m}.$$

3) *Покладаємо*

$$x_{n+1} = \frac{1}{m} x_{1,n} + \frac{1}{m} x_{2,n} + \dots + \frac{1}{m} x_{m,n}$$

$n := n + 1$ , *переходимо на крок 2.*

Також в роботі [1] було встановлено, що послідовність середніх по Чезаро:

$$\frac{\sum_{i=1}^n \lambda_i x_i}{\sum_{i=1}^n \lambda_i} \quad (2)$$

за певних умов слабо збігається до розв'язку включення 1.

На практиці часто обчислення значень  $J_{\lambda_n A_i} x_n$  для всіх  $i = \overline{1, m}$  потребує багато обчислювальних ресурсів. Щоб пришвидшити ітераційний процес, на кожному кроці можемо обчислювати лише певну кількість цих значень. Отримаємо

### *Рандомізований алгоритм*

1) Задаємо  $\{\lambda_n\} \subseteq (0, +\infty)$ ,  $x_1 \in \mathcal{H}$ ;  $n := 1$ .

2) Випадковим чином вибираємо  $k$  індексів  $\{i_1, i_2, \dots, i_k\}$  з множини  $\{1, 2, \dots, m\}$ ,  $k < m$

3) Для кожного з обраних індексів обчислюємо елементи

$$x_{i,n} = J_{\lambda_n A_i} x_n, \quad i \in \{i_1, i_2, \dots, i_k\}.$$

3) Покладаємо

$$x_{n+1} = \frac{1}{k} x_{1,n} + \frac{1}{k} x_{2,n} + \dots + \frac{1}{k} x_{i_k,n}$$

$n := n + 1$ , переходимо на крок 2.

Постає питання про властивості цього алгоритму, а саме:

1. Збіжність ітераційного процесу. Оскільки алгоритм - рандомізований, то доцільніше говорити про збіжність послідовності випадкових величин (в середньому, майже напевно).
2. Оцінка швидкості збіжності.

Потрібно:

- Встановити істотні припущення про оператори  $A_i$  та спосіб отримання вибірки.
- Сформулювати і довести теореми про збіжність, а також інші проміжні результати.
- Розглянути важливі частинні випадки

## 2 Актуальність проблеми

План:

1. Застосування в оптимізації: опуклі недиференційовні функції, субградієнт, , необхідна умова екстремуму.
2. Приклади задач:
  - мінімізація математичного сподівання
  - Мінімізація суми функцій:  $f_1 + f_2 \rightarrow \min$ , тоді необхідна умова екстремуму має вигляд  $0 \in (\partial f_1 + \partial f_2)(x)$ . Якщо другий доданок має спеціальний вигляд, це дозволяє застосовувати кращі алгоритми.
3. Де виникає  $0 \in (A + B)(x)$ 
  - (а) Умовний естремум:  $f \rightarrow \min_C$ . Необхідна умова:  $0 \in \partial f(x) + N_C x$
  - (б) Пошук сідлової точки функції Лагранжа:  $0 \in \begin{pmatrix} \nabla_1 L(x, y) \\ -\nabla_2 L(x, y) \end{pmatrix} + N_{C \times D}(x, y)$
4. Застосування в машинному навчанні <https://arxiv.org/pdf/1403.5074.pdf>. Розподілені обчислення, федеративне навчання, stochastic gradient descend.

## 3 Стаття Bianchi: ергодична збіжність

### 3.1 Постановка задачі

Розглядається сім'я операторів  $A(s, x) : E \times \mathcal{H} \rightarrow 2^{\mathcal{H}}$ . Наявність першої змінної дає змогу представити випадковий вибір одного оператора із сукупності на кожному кроці.

Уявімо сім'ю операторів, що індексуються множиною  $E$ :  $\{A_s\}_{s \in E}$ . У найпростішому випадку  $E = 1, 2, \dots, n$ , тобто, операторів - скінчена кількість. Тепер нехай  $(\xi_n(\cdot)) \subset E$  - послідовність випадкових величин, де  $\xi_n$  - випадково обраний індекс на кроці  $n$ . Тоді  $A(\xi_n, \cdot)$  - випадково обраний оператор на кроці  $n$ .

Бачимо, що якщо  $\xi_n$  реалізує вибір серед  $\{1, 2, \dots, m\}$ , де всі наслідки рівноможливі, то це частинний випадок нашої задачі, бо тут обирається лише один оператор із сукупності.

Автор розглядає ітераційну процедуру:

$$x_{n+1} = J_{\lambda_n A(\xi_{n+1}, \cdot)}(x_n) \quad (3)$$

та прагне довести збіжність майже напевно послідовності середніх за Чезаро:

$$\frac{\sum_{i=1}^n \lambda_i x_i}{\sum_{i=1}^n \lambda_i}$$

Збіжність такої послідовності середніх автор називає *ергодичною збіжністю*.

Автор шукає розв'язки включення

$$0 \in \mathbb{E}[A(\xi, \cdot)] \quad (4)$$

де справа стоїть математичне сподівання Аумана. Для нашого випадку воно має вигляд

$$\mathbb{E}[A(\xi, \cdot)] = \frac{1}{m} \sum_{i=1}^m A_i(x)$$

Зрозуміло, що тоді включення 4 еквівалентне:

$$0 \in \sum_{i=1}^m A_i(x)$$

що є частинним випадком нашої задачі.

### 3.2 Основні поняття

1. Випадкові величини
2. Математичне сподівання Аумана

### 3.3 Основні результати

(in progress)

**Теорема 1.** Нехай виконуються припущення 1-5. Нехай також всі області визначення  $D_s$  співпадають для всіх  $s$  поза  $\mu$ -нехтовною ("μ-negligible") множиною. Нехай  $(x_n)$  - послідовність, що дається формулою 3, а  $(\bar{x}_n)$  - послідовність середніх Чезаро. ....

### 3.4 Висновок

Отже, можна використати результати цієї статті для випадку, коли на кожному кроці з сукупності операторів обирається лише один.

## 4 Випадок $A = \partial f$

Важливий частинний випадок нашої задачі - коли  $A(\cdot) = \partial f(\cdot)$  - субградієнт. Відомо, що якщо  $f$  - власна функція (proper function), то  $\partial f(\cdot)$  - монотонний оператор [3].

Одним із головних застосувань задачі є пошук екстремумів опуклих недиференційовних функцій. Аналогом теореми Ферма є таке твердження [3]:

**Теорема 2** (Теорема Ферма для опуклих функцій). *Нехай  $f \in \Gamma_0(\mathcal{H})$ , тоді*

$$\arg \min f = \text{zer } \partial f = \{x \in \mathcal{H} \mid 0 \in \partial f(x)\}$$

Всюди надалі будемо говорити про мінімізацію цільової функції:

$$f \rightarrow \min \tag{5}$$

Зазвичай ми робимо такі припущення про  $f(x)$ :

1.  $f : \mathcal{H} \rightarrow (-\infty, \infty]$  - власна (proper), замкнена і опукла.
2. Множина розв'язків задачі 5 є непорожньою.
3. Ми маємо доступ до оракула, який для довільної точки  $x$  видає випадковий субградієнт  $g(x) \in \partial f(x)$ .

### 4.1 Градієнтний спуск

У випадку гладкої функції існує градієнтний метод пошуку екстремуму. Ітераційний процес методу для задачі мінімізації має вигляд:

$$x_{n+1} = x_n - \lambda \nabla f(x_n)$$

, де  $\lambda$  вибирається таким чином, щоби гарантувати збіжність методу. Також є різні оцінки швидкодії градієнтного спуску, які потребують, щоби  $\lambda$  вибиралася за певною формулою.

По аналогії, можемо розглянути субградієнтний метод:

$$x_{n+1} = x_n - \lambda g(x_n) \tag{6}$$

Отримали, замінивши  $\nabla f$  на  $g(x_n) \in \partial f(x_n)$  - довільний субградієнт. Для цього алгоритму справджується така теорема:

**Теорема 3** (Збіжність алгоритму субградієнтного спуску). *Нехай окрім згаданих вище умов справджується:*

1. Існує така стала  $M > 0$ , що для всіх  $x \in \mathbb{R}^n$  і для всіх  $g(x) \in \partial f(x)$  виконується

$$\|g(x)\|_2 \leq M$$

Нехай  $x_*$  - найближчий розв'язок до  $x_0$ ,  $R_0 = \|x_0 - x_*\|_2$  та  $\lambda = \frac{R_0}{M\sqrt{N+1}}$ . Тоді через  $N$  ітерацій градієнтного спуску маємо

$$f(\bar{x}_N) - f(x_*) \leq \frac{MR_0}{\sqrt{N+1}}$$

де  $\bar{x}_N = \frac{1}{N+1} \sum_{k=0}^N x_k$ . Окрім того, для досягнення точності  $\epsilon$  по функції  $(f(\bar{x}_N) - f(x_*))$  метод достатньо запустити на  $N = O(\frac{M^2 R_0^2}{\epsilon^2})$

## 4.2 Проксимальний алгоритм

Нехай цільова функція розкладається є сумою двох частин, і задача має вигляд:

$$F(x) = f(x) + R(x) \rightarrow \min_{x \in \mathbb{R}^n}$$

за теоремою Ферма та властивостями субградієнта, ця задача еквівалентна такій:

$$0 \in Ax + Bx, \text{ де } A = \partial f(x), B = \partial R(x)$$

Тоді використовується проксимальний алгоритм, який в класичному випадку має вигляд:

$$x_{n+1} = \text{prox}_{\lambda R}(x_n - \lambda \nabla f(x_n)), \text{ де } \text{prox}_R(x) = \arg \min_{y \in \mathbb{R}^n} \{R(y) + \frac{1}{2}\|y - x\|_2^2\}$$

Можна отримати субградієнтний проксимальний метод, замінивши градієнт  $\nabla(\cdot)$  на довільний субградієнт  $g \in \partial(\cdot)$ :

$$x_{n+1} = \text{prox}_{\lambda R}(x_n - \lambda g(x_n))$$

Зазвичай цей алгоритм застосовують тоді, коли можна легко обчислити  $\text{prox}_R$ .

## 4.3 Проекційний алгоритм для пошуку умовного екстремуму

Класичний вигляд ітераційного процесу:

$$x_{n+1} = P_C(x_n - \lambda_n \nabla f(x_n))$$

Як і раніше, переходимо від градієнтів  $\nabla f(x_n)$  до субградієнтів  $g(x_n) \in \partial f(x_n)$ , отримаємо проекційний субградієнтний метод:

$$x_{n+1} = P_C(x_n - \lambda_n g(x_n))$$

Можна сформулювати теорему про збіжність, не враховуючи стохастичну природу величини  $g(x_n)$ . У книзі [4] наведений результат, згідно з яким метод буде збігатися незалежно від того, яким буде  $g(x_n)$ . Також ця теорема дає оцінку швидкості збіжності.

Інший підхід - розглянути послідовність ітерацій алгоритму  $(x_n)$  як послідовність випадкових величин. У книзі [4] доведена збіжність послідовності *найкращих отриманих значень*:

$$\mathbb{E}(f_{best}^{(n)}) \rightarrow f_{opt} \text{ при } k \rightarrow \infty$$

## А Основні визначення та позначення

- $\mathcal{H}$  - гільбертовий простір зі скалярним добутком  $\langle \cdot | \cdot \rangle$  та нормою  $\| \cdot \|_2$ .
- Субдиференціал опуклої функції  $f(x)$  в точці  $x$  - це множина  $\partial f(x) := \{x \in \mathcal{H} \mid \forall y \in \mathcal{H} \langle y - x | f(y) - f(x) \rangle \geq 0\}$ . Субдиференціалом також називається відповідне багатозначне відображення.  
*Субградієнтом* називається будь-який елемент цієї множини.
- $\Gamma_0(\mathcal{H})$  - множина власних (proper) напівнеперервних знизу функцій з  $\mathcal{H}$  в  $(-\infty, \infty]$ .
- Проксимальний оператор  $\text{prox}_f(x) := \arg \min_{y \in \mathcal{H}} \{f(y) + \frac{1}{2}\|y - x\|_2^2\}$ , де  $f \in \Gamma_0(\mathcal{H})$ .
- Оператор проектування на множину  $P_C := \arg \min_{y \in C} \|x - y\|^2$ . Якщо  $C$  - непорожня, замкнена та опукла множина, то для кожного  $x \in \mathcal{H}$  існує єдина проекція  $P_C(x)$ .

## Література

- [1] В. В. Семенов *Параллельная декомпозиция операторных включений с максимальными монотонными операторами*. Журнал обчислювальної та прикладної математики, 2013, No 2 (112), УДК 517.9 [Journal of Computational & Applied Mathematics]
- [2] Pascal Bianchi *Ergodic convergence of a stochastic proximal point algorithm*, 2016, <https://arxiv.org/abs/1504.05400>
- [3] Heinz H. Bauschke, Patrick L. Combettes *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*, 2011, DOI 10.1007/978-1-4419-9467-7
- [4] Amir Beck *First-order methods in optimizations*, 2017, <https://doi.org/10.1137/1.9781611974997>